



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvaldivieso@uc.cl) —

Resumen clase 6

¿Qué es Streamlit?

- Streamlit es una librería open-source de Python, que nos permite crear aplicaciones web.
- Su ventaja es que no es necesario aprender tecnologías web (JavaScript) para hacer visualizaciones interactivas.
- Tiene compatibilidad con Altair, Matplotlib, plotly, folium*, entre otros.
- Documentación: [Streamlit documentation](#)
- Excelente tutorial: [30 days of Streamlit](#).

Extra

Creé una versión 2 la demo de la clase pasada

- Link del código: <https://github.com/Hernan4444/demo-streamlit-vis-ml>
- Link a la demo: <https://demo-vis-ml-uc.streamlit.app/>

¿Diferencias?

1. **Intento de proteger los datos:** El *dataset* está dentro de un zip con contraseña que se carga en el mismo código usando una contraseña en variables de entorno.
2. **Integración Seaborn:** Agregué un gráfico con *seaborn*.
3. **Mejora rendimiento.** Agregué "`streamlit.form`" para la parte de *Machine Learning*. Esto hace que *streamlit* no se recarga cada vez que se cambia algún *input*. Solo lo hace cuando se presiona el botón.

Tiempo que tarda un hacker en **FORZAR TU CONTRASEÑA**

Es imprescindible que nuestras contraseñas sean complejas, números, letras, mayúsculas, minúsculas y caracteres especiales.



Número de caracteres	Solo números	Letras minúsculas	Minúsculas y mayúsculas	Números, minúsculas y mayúsculas	Números, minúsculas, mayúsculas y símbolos
4	Instant.	Instant.	Instant.	Instant.	Instant.
5	Instant.	Instant.	Instant.	Instant.	Instant.
6	Instant.	Instant.	Instant.	Instant.	Instant.
7	Instant.	Instant.	2 seg.	7 seg.	31 seg.
8	Instant.	Instant.	2 min.	7 min.	39 min.
9	Instant.	10 seg.	1 hora	7 horas	2 días
10	Instant.	4 min.	3 días	3 semanas	5 meses
11	Instant.	2 horas	5 meses	3 años	34 años
12	2 seg.	2 días	24 años	200 años	3K años
13	19 seg.	2 meses	1K años	12K años	202K años
14	3 min.	4 años	64K años	750K años	16M años
15	32 min.	100 años	3M años	46M años	1BN años
16	5 horas	3K años	173M años	3BN años	92BN años
17	2 días	69 K años	9BN años	179BN años	7TN años
18	3 semanas	2M años	467BN años	11TN años	438TN años

Clase 7: Tópicos Avanzados 1

Redes, Validación de visualización, Reducción de Dimensionalidad y Diseño de *Dashboard*

Contenidos


- Visualización de datos de red.
- Validación de Visualización
- Reducción de dimensionalidad
 - ¿En qué consiste?
 - PCA y TSNE
 - Casos de aplicación de Reducción de dimensionalidad
- Diseño de *Dashboard* (bonus - no será evaluado)

Visualización de datos de red

Dataset de red

- Representar situaciones donde existen relaciones entre dos o más ítems.
- Compuestos por datos de tipo ítem (nodos) y de tipo enlace.
- Algunos ejemplos típicos son redes sociales, red de tráfico, árbol jerárquico de una empresa, entre otros.

→ Networks




→ Trees



Dataset de red



- Se pueden aplicar en diferentes contextos.



Dataset de red

Hay redes dirigidas y no dirigidas.

- **Dirigidas:** útil para representar relaciones asimétricas. Por ejemplo:
 - Jefaturas: Sofía es la jefa de María en la empresa.
 - Seguir a un usuario en redes sociales: Hernán siguió a Nicolas en Instagram y Twitter.
- **No dirigidas:** útil para representar relaciones simétricas. Por ejemplo:
 - Amistades de Facebook: Si Hernán es amigo de Nicolás, Nicolás también será amigo de Hernán.




Dataset de red

Los nodos y/o enlaces pueden contener atributos.

SHAKESPEAREAN TRAGEDY



TITUS ANDRONICUS
Number of characters 36 | 50% Network density




HAMLET
Number of characters 37 | 39% Network density



KING LEAR
Number of characters 33 | 45% Network density

Dataset de red

Pueden ser del tipo jerárquico




Dataset de red - Métricas

- En este tipo de dataset existen diferentes métricas, generalmente numéricas, que entregan una pequeña descripción de la red o nodos.
 - **De la red:** cantidad de nodos, cantidad de enlaces, diámetro (distancia máxima entre nodos de una red) y distancia promedio entre nodos
 - **De cada nodo:** grado (cantidad de conexiones) y cercanía (distancia promedio con otros nodos)
- Si están interesados en profundizar sobre medidas en redes, pueden revisar el siguiente enlace: [4. Measuring Networks Part 1: Centrality and Global Measures](#)

Dataset de red - Métricas

- Cantidad de nodos: 24
- Cantidad de enlaces: 106
- Diámetro (distancia máxima entre nodos de una red): 4
- Distancia promedio entre nodos: 2.23




Dataset de red - Métricas

Nodo Gandalf

- Grado: 16
- Cercanía: 1.30


Name	Gandalf
Degree	16
Betweenness Centrality	27.9
Closeness Centrality	1.30
Eigenvector Centrality	0
Triangles	68
Eccentricity	2
Group	1
Pagerank	0.10



Nodo Saruman

- Grado: 7
- Cercanía: 1.74

Name	Saruman
Degree	7
Betweenness Centrality	22.7
Closeness Centrality	1.74
Eigenvector Centrality	0
Triangles	12
Eccentricity	3
Group	2
Pagerank	0.031



Dataset de red - Visualización

Algunos objetivos dentro de estos datos que motivan a realizar visualizaciones son:

- **Los caminos entre nodos.**
 - Conocer la distancia entre nodos específicos.
 - Conocer si están conectados directamente.
 - Conocer qué nodos hay en el camino.
- **La topología**, que es la forma general de la red, cómo se interconectan sus nodos: de forma tanto directa como indirecta.
 - Hay algún nodo que conecta con todos.
 - Hay *clusters* de nodos.
 - Hay nodos sin ninguna conexión.

Dataset de red - Visualización

Existen muchas formas de visualizar estos datos.

- [Graph Visualization](#)
[Introduction / Brian Staats /](#)
[Observable](#)

En esta clase abordaremos 3 formas principales de visualizar:

- Nodo-enlace.
- Matriz de adyacencia.
- *Idioms* de contención.

6 WAYS TO VISUALIZE



ROBERT GOVE • TWO SIX LABS


FORCE
DIRECTED




GROUP IN A BOX




RADIAL




SEMANTIC
SUBSTRATE



ARC
DIAGRAM



MATRIX
DIAGRAM




Nodo-enlace y Matriz de Adyacencia

Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

- También conocido como **grafo**.
- **Nodos (puntos o áreas)**: tamaño, color, y posición.
- **Enlaces (líneas o áreas)**: ancho, color y tipo de línea. También puede incluir una **flecha** (en lugar de línea) para identificar tipos de relaciones.




Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

Gráfico ideal para entender la **topología** de la red.

- Encontrar todos los caminos usando conexiones de la red entre dos nodos específicos.
- Encontrar el camino más corto entre dos nodos.
- Encontrar todos los nodos directamente adyacentes a un nodo específico.
- Encontrar nodos importantes dentro de la red en términos de conectividad.






Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

Una de las tareas más difíciles es intentar que el grafo se vea lo "más entendible posible".

- No se superpongan los nodos.
- Evitar la intercepción de líneas.






Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

🤔 ¿Cómo determinar la posición de los nodos?

- Existen gráficos del tipo nodo-enlace que fijan las posiciones de los nodos. Aunque su implementación es difícil de realizar.
 - **Diagrama de Arco** - Utiliza un eje (X o Y) para posicionar todos los nodos.
 - **Diagrama de Cuerdas Sin Cinta** - Utiliza una disposición radial para posicionar los nodos.
 - **Hive plot** - Genera múltiples ejes.





Nodo-enlace y Matriz de Adyacencia

Nodo-enlace

🤔 ¿Cómo determinar la posición de los nodos?

- Simular fuerzas físicas como si fueran partículas.
- Los enlaces provocarán, en la simulación, que 2 nodos se intenten juntar, mientras que la ausencia de estos permitirá que se alejen los nodos.
- Esta técnica hace que la posición ya no codifique ninguna información.
- Más fácil de implementar y barata computacionalmente que los otros enfoques.




Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - Red de sabores

- Cada nodo denota un ingrediente.
- El color del nodo indica la categoría de alimentos.
- El tamaño del nodo codifica la cantidad de recetas que usan dicho ingrediente.
- Dos ingredientes están conectados si comparten un número significativo de compuestos de sabor.
- El grosor del enlace representa el número de compuestos compartidos entre los dos ingredientes.


Flavor Network

Yong-Yeol Ahn, Sebastian Ahnert, James P. Bagrow, and A.-L. Barabási



Flavor network. Culinary ingredients (nodes) and their chemical relationship are illustrated. The color of each ingredient represents the food category that the ingredients belong to, and the size of an ingredient is proportional to the frequency we use (collected from online recipe databases) experiences on, also (spices, ingredients). Two culinary ingredients are connected if they share more flavor compounds. We extracted the list of flavor compounds in each ingredient from the food. (Formally, based on flavor ingredients list) and then applied a backbone extraction method by Serres et al. (2015) and apply to pick statistically significant links between ingredients. The thickness of an edge represents the number of shared flavor compounds. To reduce clutter, edges are bundled based on the algorithm by Dorner (2010) (<http://www.ece.utdallas.edu/~dorner/>).

Nodo-enlace y Matriz de Adyacencia




Nodo-enlace - Animes vistos

- Cada nodo es una serie.
- El tamaño del nodo codifica la cantidad de personas que ven esa serie.
- Dos series están conectadas si hay muchas personas que vieron ambas series.
- El grosor del enlace representa el número de personas que vieron ambas series.

Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - Neural Network Playground


- Cada nodo es una neurona o *feature*.
- Los enlaces son los pesos de la red.
- El color del enlace representa un peso positivo o negativo



Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - 2D Visualization CNN


- Cada nodo es una unidad del filtro de una capa o bien una unidad de una capa *fully connected*
- Los enlaces unen un nodo con los pesos utilizados de la capa anterior
- El color del enlace representa el valor del nodo de la capa anterior.



Nodo-enlace y Matriz de Adyacencia

Nodo-enlace - Conexiones cables submarinos




- También se puede ver como un mapa de flujo.
- Los enlaces unen el inicio y fin de un cable submarino.



Nodo-enlace y Matriz de Adyacencia

Nodo-enlace


- **Ventaja:** Intuitivo para el humano de entender
- **Desventaja:** la escalabilidad. Si hay **más de 4 veces** enlaces que nodos, o son miles de nodos, pueden generarse bolas de pelos y se recomienda utilizar otro *idiom*.



Nodo-enlace y Matriz de Adyacencia



Matriz de Adyacencia

- Disposición de los nodos en los bordes de una matriz. Cada celda pintada indica la presencia de una conexión.
- Suele ir bien con redes grandes aunque es menos intuitiva de entender que el diagrama Nodo-enlace.



Nodo-enlace y Matriz de Adyacencia

Matriz de Adyacencia



Nodo-enlace y Matriz de Adyacencia

Matriz de Adyacencia

Algunas tareas eficientes son:


- Estimación del número de nodos → Tamaño de la matriz
- Estimación del número de enlaces. → Cantidad de celdas pintadas
- Encontrar los nodos más conectados. → Filas/columnas muy pintada
- Encontrar un nodo según etiqueta. → Explorar nombres de fila/columna
- Encontrar un enlace entre un par de nodos. → Intercepción entre fila/columna

Jerarquías y Árboles

Jerarquías y Árboles

Caso particulares de red donde **no existen ciclos** en sus conexiones.

- Dado un nodo X, no existe un camino que parta en dicho nodo y termina en el mismo nodo pasando solo 1 vez por cada conexión del camino.





En este tipo de red, hay 4 conceptos importantes:

1. **Nodo hijo:** es el nodo receptor de una conexión. B es hijo de A, D es hijo de C.
2. **Nodo padre:** es el nodo de donde sale una conexión. A es padre de C, C es padre de E.
3. **Nodo hoja:** son los nodos que no tienen hijos. B, D y E son nodos hojas.
4. **Nodo raíz:** es el nodo que no tiene padre. A es nodo raíz.



Jerarquías y Árboles

- Este tipo de dato se conoce como **árbol** o **de jerarquía**.
- Si bien podemos usar los gráficos nodo-enlace o matriz de adyacencia para codificar un árbol. El hecho de que exista un orden (la jerarquía) **las posibilidades de estos gráficos cambian y aumentan**.



Jerarquías y Árboles



Es común recurrir al uso de **contención espacial** para comunicar jerarquía.



Jerarquías y Árboles

Treemap


- Cada área representa un nodo.
- El tamaño **puede** codificar algún atributo numérico. Este canal se aplica a nodos hojas y el tamaño de los demás nodos se obtiene a partir de la suma de sus hijos.
 - Permite apreciar las contribuciones de distintas secciones de la jerarquía dentro de la totalidad de la red.
- El color **puede** codificar un atributo categórico.



Jerarquías y Árboles

Treemap

- Eficientes en espacio y buenos para hacer notar valores anormales para el atributo codificado.
- Ineficientes para tareas relacionadas a la topología de la red.



Jerarquías y Árboles

Treemap




Fuente: [NVIDIA is one of the largest threats to the US stock market](#)

Jerarquías y Árboles

Circle packing








- Versión circular del *Treemap*.
- En muchos casos es más fácil de leer e interpretar que el *Treemap*.
- Uso del espacio menos eficiente, y para jerarquías grandes el espacio necesario puede ser muy grande para apreciar detalles.



Jerarquías y Árboles

¡Existen muchas opciones más!

Es nuestro trabajo evaluar cuál diseño es el adecuado para nuestros datos y tareas.



Resumen de conceptos importantes

- **Red (*network*):** tipo de *dataset* donde tenemos ítems (nodos en este caso) y conexiones/relaciones entre ítems (enlaces en este caso).
- **Grafo:** visualización donde cada nodo se representa con un área (generalmente círculo) y se usan líneas para representar la conexión.
- **Diagrama nodo-enlace:** otro nombre para un grafo.
- **Árbol:** tipo particular de red donde no hay ciclos en las conexiones.

Redes y Python

- Una librería muy popular para analizar y dibujar grafos es [NetworkX](#)
 - Permite calcular métricas dado un grafo y crear visualizaciones estáticas.
 - Permite seleccionar diferentes algoritmos para posicionar los nodos.
 - Dibuja el grafo utilizando Matplotlib por debajo.
 - [Tutorial](#) y [Galería](#)
- Otra librería conocida es [pyvis](#)
 - Genera visualizaciones interactivas de grafos.
 - Utiliza código JS y HTML por detrás para permitir la interactividad.
 - [Tutorial](#)
- Bonus: [Demo Networkx y pyvis](#)

Validación de visualización

Validación de visualización

Aplicando el *framework* de Tamara Munzner... *what, why y how*



Domain situation

Situación de dominio



Data/task abstraction

Abstracción de datos y tareas



Visual encoding/interaction idiom

Codificación visual e interacciones



Algorithm

Algoritmo


Validación de visualización

Paso 1 - Situación de dominio

Objetivo: Conocer al usuario objetivo

🤔 ¿Qué hacer? 🤔

- Entrevistas
- Campos de observación
- Revisión de literatura
- Luego de hacer la visualización, confirmar si el usuario la utiliza.



Validación de visualización

Paso 2 - Abstracción de datos y tareas

Objetivo: Entender datos y definir mensaje (tarea visual)

🤔 ¿Qué hacer? 🤔

- Revisar *dataset*
- Entender qué significa cada atributo y/o ítem
- Determinar cuál es el mensaje a transmitir con el gráfico.
- Luego de hacer la visualización, confirmar si el mensaje se logra entender.




Validación de visualización

Paso 3 - Codificación visual

Objetivo: Definir decisiones de diseño

🤔 ¿Qué hacer? 🤔

- Elegir qué gráfico será el indicado.
- Diagramar/bocetos.
- Pensar en posibles justificaciones para elegir dicho gráfico.
- Revisar que las decisiones de diseño tengan sentido.




Validación de visualización

Paso 4 - Algoritmo

Objetivo: Elaborar

🤔 ¿Qué hacer? 🤔

- Confeccionar visualización.
- Llevar las decisiones de diseño a la herramienta/código.
- Validar que el resultado cargue dentro de los tiempos y todas las decisiones estén implementadas correctamente.



Validación de visualización

Caso aplicado

fecha_siniestro	descripcion_region	descripcion_comuna	tipo_veh	marca_veh	color_veh	...
10/12/2015	Región Metropolitana de Santiago	Vitacura	AUTOMOVIL	TOYOTA	Blanco	...
17/11/2015	Región Metropolitana de Santiago	Santiago	AUTOMOVIL	HYUNDAI	Rojo	...
16/04/2016	Región de Los Lagos	Puerto Montt	CAMIONETA	SUBARU	Plateado	...
16/05/2016	Región del Biobío	Laja	STATION WAGON	KIA	Negro	...
28/12/2016	Región Metropolitana de Santiago	Recoleta	FURGON	SUZUKI	Blanco	...
...	...	...	...	...	...	...

Validación de visualización


Contexto: Datos de robo de vehículos

fecha_siniestro	descripcion_region	descripcion_comuna	tipo_veh	marca_veh	color_veh	...
10/12/2015	Región Metropolitana de Santiago	Vitacura	AUTOMOVIL	TOYOTA	Blanco	...
17/11/2015	Región Metropolitana de Santiago	Santiago	AUTOMOVIL	HYUNDAI	Rojo	...
16/04/2016	Región de Los Lagos	Puerto Montt	CAMIONETA	SUBARU	Plateado	...
16/05/2016	Región del Biobío	Laja	STATION WAGON	KIA	Negro	...
28/12/2016	Región Metropolitana de Santiago	Recoleta	FURGON	SUZUKI	Blanco	...
...	...	...	...	...	...	...


Validación de visualización

Estado del arte


- [Gallery - Multiclass Density Maps](#)
- Técnicas de filtros, agrupación, colores, opacidad, etc.
- Limitaciones:
 - No hay evaluación sobre cuál usar.
 - ¿cómo incluyo la información temporal?



Validación de visualización




Validación de visualización




55

1110



Validación de visualización



Validación de visualización

- Para analizar la componente temporal, Lobo et al. (2015) presentan 5 interacciones para mapas geográficos:
 - *Juxtapose* (JX)
 - *Translucent Overlay* (TO)
 - *Swipe* (SW)
 - *Magic Lens* (ML)
 - *Offset Lens* (OL)
- En este estudio de usuario realizado por Svcarovic (2019), se busca evaluar los primeros 4 junto con la nueva visualización.

Podemos revisarlas en [este enlace](#).

Validación de visualización

Se implementaron preguntas del tipo:

- Comparar una comuna en el tiempo - ¿En qué año la comuna de **Conchalí** tuvo **mayor** porcentaje de robo de **Camionetas**?
- Comparar dos comunas en el tiempo - ¿En qué año la comuna de **San Miguel** tuvo **mayor** porcentaje de robo de autos marca **Chevrolet** que la comuna de **La Cisterna**?

Validación de visualización

Nº Comunas a comparar	Interacción	% correctas ($\pm$ error)	Tiempo total prom. ($\pm$ error)
1	JX	66.67 ($\pm$ 4.90)	33.71 ($\pm$ 1.77)
	ML	85.42 ($\pm$ 3.78)	26.82 ($\pm$ 1.12)
	SW	84.38 ($\pm$ 3.97)	26.16 ($\pm$ 1.50)
	TO	84.38 ($\pm$ 3.80)	29.13 ($\pm$ 1.06)
2	JX	87.50 ($\pm$ 3.52)	46.35 ($\pm$ 1.97)
	ML	91.67 ($\pm$ 2.80)	44.41 ($\pm$ 1.81)
	SW	88.54 ($\pm$ 3.40)	38.82 ($\pm$ 2.02)
	TO	83.33 ($\pm$ 3.90)	48.45 ($\pm$ 2.40)


Juxtapose (JX)




Magic Lens (ML)



Swipe (SW)



Translucent Overlay (TO)



Validación de visualización

La superposición de imágenes obtuvo mejor rendimiento:

- *Juxtapose (JX)* obtuvo el **menor rendimiento**.
- *Magic Lens (ML)* y *Swipe (SW)* tuvieron los **mejores rendimientos**.
- *Magic Lens (ML)* tiene **mayor carga cognitiva** que *Swipe (SW)*.


Juxtapose (JX)




Magic Lens (ML)



Swipe (SW)




Translucent Overlay (TO)




Reducción de dimensionalidad

Reducción de dimensionalidad

- Transformación de datos multidimensionales a datos de pocas dimensiones sin perder las caracterizaciones originales.
- Son un campo de estudio importante en *data science* y estadística.



Reducción de dimensionalidad



De 4.096 dimensiones
a 2 dimensiones

Reducción de dimensionalidad



🤔 ¿Cómo funcionan estas "dimensiones"?

- En conjunto, todas las nuevas dimensiones tratan de guardar la misma información que el ítem en su alta dimensionalidad.
- En algunos algoritmos, estas nuevas dimensiones se construyen a partir de combinar información de distintos atributos originales.

Reducción de dimensionalidad

🤔 ¿Cómo funcionan estas "dimensiones"?

- En algunos algoritmos, estas nuevas dimensiones se construyen a partir de combinar información de distintos atributos originales.




Reducción de dimensionalidad

🤔 ¿Cómo funcionan estas "dimensiones"?

- **Scree plot**

Indica cuanto es el porcentaje de *Explained variance* por cantidad de dimensiones que usemos.

Explained variance es la diferencia entre la varianza de los datos originales y la varianza de los datos generados con las N dimensiones.



Reducción de dimensionalidad

Algoritmos existentes:

- PCA
- LDA
- T-SNE
- Entre otros ...

En visualización se ocupan muchas veces para mostrar espacialmente y en dos dimensiones un *dataset*. De tal forma que ítems próximos realmente sean similares según sus todos sus atributos originales, y qué ítems lejanos sean realmente diferentes.

Reducción de dimensionalidad

Algoritmos existentes:



- **PCA**
- LDA
- **T-SNE**
- Entre otros ...

Vamos a entender la intuición de estos 2 algoritmos muy utilizados en la práctica.

Reducción de dimensionalidad

PCA

- Busca describir la ubicación de cada punto como una **combinación lineal de los pesos de cada eje**.
- El algoritmo debe encontrar los ejes, desde el que captura más varianza en adelante





Reducción de dimensionalidad

PCA - Calculo

Una forma típica para calcular el PCA es

1. Normalizar los datos (por columnas).
2. Calcular la matriz de covarianza.
3. Calcular valores y vectores propios de la matriz de covarianza.
4. Proyectar los datos originales en la nueva base (vectores propios).



[How to Calculate Principal Component Analysis \(PCA\) from Scratch in Python - MachineLearningMastery.com](https://machinelearningmastery.com/how-to-calculate-principal-component-analysis-pca-from-scratch-in-python/)



Reducción de dimensionalidad

PCA - Ventaja


- Una vez aprendido los ejes, puede posicionar un nuevo dato en alta dimensión a baja dimensión.
- Intuitivo de entender dado que un eje es solo la combinación de atributos originales. Esto ayuda a entender cuáles atributos son los que más variación tienen.
- La ejecución es determinista y solo es un conjunto de operaciones.



Reducción de dimensionalidad

PCA - Desventajas



- Para preservar la varianza, datos alejados en alta dimensión, intenta que estén alejados en baja dimensión.
- 🤔 ¿Cuál distancia consideramos aquí?
- En determinados escenarios, el no poder considerar otro tipo de combinaciones supone perder mucha información



Reducción de dimensionalidad

PCA - Desventajas II


- Muy influenciado por datos atípicos. Estos alteran fácilmente la varianza de datos.
- No siempre reducir la dimensionalidad implica hacer combinaciones lineales de los atributos



Reducción de dimensionalidad

TSNE: *T-distributed Stochastic Neighbor Embedding*


- Reducción de Dimensionalidad No Lineal → No se hacen combinaciones de atributos.
- Algoritmo iterativo que paso a paso va ajustando los datos a la baja dimensión.



Reducción de dimensionalidad

TSNE - Calculo

1. Mide la distancia de los puntos en alta dimensión (p_{ij})




$$p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma^2)}{\sum_k \sum_{l \neq k} \exp(-\|\mathbf{x}_k - \mathbf{x}_l\|^2 / 2\sigma^2)}$$

Reducción de dimensionalidad

TSNE - Calculo

1. Mide la distancia de los puntos en alta dimensión (p_{ij})
2. Posiciona los datos al azar y mide distancia en baja dimensión (q_{ij})



Reducción de dimensionalidad

TSNE - Calculo

1. Mide la distancia de los puntos en alta dimensión (p_{ij})
2. Posiciona los datos al azar y mide distancia en baja dimensión (q_{ij})
3. Actualiza los pesos en baja dimensión apoyándose de esta fórmula

$$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)}$$

Penalizamos los casos en que la distancia es grande en el espacio de alta dimensión (p_{ij}) y es baja en el espacio de baja dimensión (q_{ij}).

→ **No acerquemos puntos que estaban lejos antes.**


→ Le da lo mismo si un punto que estaba cerca antes, ahora queda lejos.

Reducción de dimensionalidad

TSNE - Calculo


Forma más visual

Stage 1




Stage 2



a. Randomly project cells as points on a low-dimensional plot



b. Determine similarities between points





c. Move the points around until the similarities between points in low dimension resemble the similarities in high dimensions



Reducción de dimensionalidad

TSNE - Calculo

Forma más visual





*gif

Reducción de dimensionalidad

TSNE - Ventaja

- Abre la puerta a crear nuevas dimensiones que no se pueden representar como combinación lineal de las ya existentes.
- Los datos atípicos no le afectan.
- Mas sensible a datos similares.



Reducción de dimensionalidad


TSNE - Desventaja

- Las nuevas dimensiones no se pueden mapear fácilmente a las originales.
- La baja interpretación de su algoritmo (*black box*), es decir, permite visualizar muy bien datos, pero no genera, por ejemplo, una serie de ecuaciones fácilmente interpretables como hace el PCA.
- No es un proceso determinista, por lo que, a pesar de emplear los mismos datos, los resultados pueden variar.
- Si llegan nuevos datos, hay que ejecutar todo de nuevo.

Reducción de dimensionalidad

TSNE - Desventaja

- Dependerá de los hiper-parámetros que nosotros definamos previamente
 - *Perplexity*: forma de medir el efecto que tendrán los vecinos de cada punto.



Original



Perplexity: 2
Step: 5,000



Perplexity: 5
Step: 5,000



Perplexity: 30
Step: 5,000



Perplexity: 50
Step: 5,000




Perplexity: 100
Step: 5,000

Reducción de dimensionalidad - Casos de aplicación

Cantantes similares


- Cada cantante se representa con información de sus canciones.
- Se construye un vector (x, y) por cantante mediante reducción de dimensionalidad.



Reducción de dimensionalidad - Casos de aplicación

Visualización de *Embeddings*


- ¿Qué es *embeddings*? Representación numérica de algún elemento (texto, imagen, dato tabular, etc.)
- Se construye un vector (x, y, z) por *embedding* para identificar elementos "similares".



Reducción de dimensionalidad - Casos de aplicación

Comparación visual de técnicas



- Cada punto es una imagen de un número (0 al 9) cuyo color indica su clase.
- La posición se determina según el vector de *feature* que se obtiene del modelo de DL (LeNet) y con reducción TSNE.
- Se probaron diferentes técnicas de clasificación (*SingleTask*, *Multitask* tradicional y *Multitaks* con pérdidas ponderadas) y entrenando con diferente cantidad de épocas.



Reducción de dimensionalidad - Casos de aplicación

Comparación visual de efectividad de *datasets*


- Cada punto es una imagen de un tifón cuyo color es su categoría (potencial del tifón).
- La posición se determina según el vector de *feature* que se obtiene del modelo de DL (VGG-16) y con reducción TSNE.
- Se probó el mismo modelo pero usando el *dataset* original vs uno preprocesado.



● Normal ● Strong ● Very Strong ● Violent

Reducción de dimensionalidad

En términos del *Framework* de Tamara Munzner...



Derivamos nuevos datos

Identificamos clusters

Definir un nombre

Reducción de dimensionalidad

Reconstrucción de datos luego de aplicar reducción




Imagen de 800x600
(480000 pixeles)

Reducción de dimensionalidad

Reconstrucción de datos luego de aplicar reducción

First 2 Components



First 3 Components




First 10 Components




First 20 Components



First 4 Components



First 5 Components



First 50 Components



First 100 Components




Imagen de 800x600
(480000 pixeles)

Reducción de dimensionalidad

Reconstrucción de datos luego de aplicar reducción

First 2 Components



First 3 Components




First 10 Components




First 20 Components



First 4 Components



First 5 Components



First 50 Components



First 100 Components



Imagen de 800x600
(480000 pixeles)

Con 100 dimensiones basta para
generar una imagen bien similar.

Diseño de *Dashboard*

(Bonus - no será evaluado)

Herramientas para *dashboards*

- **No sirve de mucho centrarse en las herramientas.**
- La mayoría de las herramientas modernas permite hacer excelentes visualizaciones y *dashboards*.
- Ninguna herramienta por sí sola va a producir visualizaciones efectivas **sin una persona que entienda muy bien qué y a quién está dirigida la visualización.**
- Aprender una herramienta ya te abre las puertas a otras herramientas.

Tableau vs Power BI





Tableau vs Power BI







Tableau vs Power BI




Herramientas para *dashboards*

Preguntas fundamentales para guiar el proceso de elegir una herramienta acorde a las necesidades.

- ¿Incluye los **gráficos** necesarios para satisfacer las necesidades del negocio y mostrar los análisis correctos?
- ¿Cuál es el **volumen de información** que puede procesar?
- ¿Cuál es la **curva de aprendizaje** de la herramienta?
- ¿Cuáles son las principales **limitaciones**? ¿En qué medios funciona?
- ¿Cuál es nuestra disposición para la logística de adquirir e implementar esta herramienta, en términos de **costo, facilidad de integración y mantenimiento**?

Dashboards


- *Display de la información más relevante para el logro del objetivo consolidado y arreglado en una sola pantalla de modo que pueda ser monitoreado con una mirada (S. Few 2004)*
- Data + Visualization + User Interface (UI)
- Los datos típicamente incluyen algunas métricas y KPIs, valores que representan historia, tendencias, distribuciones, comparaciones, etc.
- La UI permite al usuario **interactuar con los datos**




Storytelling

- En el contexto de *Business Intelligence* (BI), consiste en transmitir un mensaje (contar una historia)... pero incluyendo datos.
- Suele ser un segundo paso *post dashboard*.
- Exige definir previamente uno o más mensajes que el usuario receptor debe retener o usar para tomar decisión.
- Se selecciona de forma precisa la información más relevante para apoyar el mensaje.



Mobile trends in shopping



Smartphone owners



Online sales



Mobile is changing the way people shop and buy



84% of smartphone users shop on their phones

45% of all online shopping purchases happen on a smartphone

Source: Emarketer, [Region, Year]

Storytelling

- En el contexto de *Business Intelligence* (BI), consiste en transmitir un mensaje (contar una historia)... pero incluyendo datos.
- Suele ser un segundo paso *post dashboard*.
- Exige definir previamente uno o más mensajes que el usuario receptor debe retener o usar para tomar decisión.
- Se selecciona de forma precisa la información más relevante para apoyar el mensaje.



Dashboards vs Storytelling

- *Dashboard*
 - Conjunto de visualizaciones en una vista que presentan un tema en común.
 - Utilizado generalmente para el trabajo diario en la empresa o para un **análisis de los datos**.
- *Storytelling*
 - Una o más visualizaciones y/o dashboard cuya secuencia permite transmitir un mensaje.
 - Utilizado generalmente en **reportes y presentaciones**.


Dashboards vs Storytelling

- *Dashboard*
 - Conjunto de visualizaciones en una vista que presentan un tema en común.
 - Utilizado generalmente para el trabajo diario en la empresa o para un **análisis de los datos**.
- *Storytelling*
 - Una o más visualizaciones y/o dashboard cuya secuencia permite transmitir un mensaje.
 - Utilizado generalmente en **reportes y presentaciones**.

Ambos tienen una gran ventaja para entender los datos, pero es importante definir cuándo ocupar cada uno.

Dashboards vs Storytelling

BEFORE




AFTER

Opportunity: **expand our training program**

Our summer promotion was effective at getting clients to register for the program, but our latest weekly training program **registrations are 50% lower** compared to the highest week in May.

RECOMMENDATION: Review current awareness and promotion strategies to drive additional registrations.


Weekly training program registrations



The volume of training sessions attended has also tapered off since May. **Center C has the highest percentage of registrations** participating in personal training sessions.

LET'S DISCUSS: What can we learn from Center C's success with program engagement?

Session engagement level by center



Dashboards vs Storytelling

- *Ejemplos*
 - Dashboard: [Portfolio Project - Global Economic Analysis 2 | Tableau Public](#)
 - Storytelling: [Why 7,000 people die needlessly every day | World News](#)
 - Scrollytelling: [Climate Zones](#)
 - Scrollytelling ML: [A visual introduction to machine learning](#)
 - Muchos ejemplos más: [The Pudding](#)

Fases en Diseño de un *Dashboard*

1. Definir

- Identificar contexto (usuarios, necesidad, medio).
- Determinar las principales **métricas** que interesa mostrar.

2. Prototipar

- Elegir la **visualización ideal** para cada una de las métricas.
- Arreglar todo en un **tablero** (usar recortes o cosas que se puedan distribuir fácilmente).
- Construir un prototipo, obtener **feedback** y volver a iterar.


3. Construir

- Obtener los **datos** necesarios y **generar** los valores de las métricas.
- Usar la **herramienta** de visualización elegida.

4. Desplegar (distintos dispositivos, *cloud*, etc)

Buenas Prácticas para Diseño de *Dashboards*

- [John Maeda: Designing for simplicity | TED Talk](#)



Buenas Prácticas para Diseño de *Dashboards*

- Utilizaremos los diferentes principios propuestos por John Maeda para guiar nuestro proceso de diseño de un *dashboard*.
- Algunos de estos transmiten lo mismo que Principios de Diseño ya enseñados en la clase anterior.

✓ Reducción

✓ Organización

✓ Tiempo

✓ Aprendizaje

✓ Diferencias

✓ Contexto

✓ Emoción

✓ Confianza

✓ Fracaso

✓ Única







Buenas Prácticas para Diseño de *Dashboards*

Reducción

- Elimina lo innecesario (*Data ink ratio*).
- No solo considera lo visual, también a la funcionalidad
- ¿Necesito este filtro? ¿Me aporta este gráfico?

Organización

- *Layout claro de los elementos.*
- Alinear elementos.
- Generalmente se utiliza top to bottom o bottom to top.



Buenas Prácticas para Diseño de *Dashboards*

Tiempo

- Esperar nos genera frustración, minimizar el tiempo del usuario.
- Tener muchos gráficos no es la solución, incluso puede jugar en contra.
- Incluir los KPIs relevantes en forma destacada y fácil de interpretar.

Contexto

- Considera el tiempo y lugar del usuario.
- ¿Celular? ¿Presentación? ¿Noticiero? ¿uso diario en la empresa?




Buenas Prácticas para Diseño de *Dashboards*

Aprendizaje

- Intentar apoyarte en la Consistencia Externa para apoyar al usuario.
- Mantener consistencia interna.
- No descartar un gráfico por ser difícil, mejor pensar como el usuario lo entienda.

Diferencias


- No caer en la monotonía de únicamente gráficos simples.
- Si tienes gráficos más complejos matizarlos con los simples.



Buenas Prácticas para Diseño de *Dashboards*

Emoción


- No llevar al extremo la simplicidad. No maximizar el *data ink ratio* en todo momento.
- A veces es bueno tener algo complejo.
- Recurrir a colores que tengan cierta percepción fuerte. Agregar un grado de diseño al *dashboard*.
- Tampoco es interrumpir el mensaje dado el diseño.



Buenas Prácticas para Diseño de *Dashboards*

Confianza y Fracaso

- Existe Control+Z, ten confianza en equivocarte e iterar.
- **Los gráficos más conocidos/simples no siempre serán la solución.**
- Los Principios de Diseño ayudan a iterar sin necesidad de recurrir a un tercero.



Buenas Prácticas para Diseño de *Dashboards*

Única

- Enfocada en el mensaje más importante ¿en qué me diferencio?
- Ajustarse al usuario para poder transmitir tu mensaje en todo caso.
- Considera más de una forma de contar la historia. Hay quienes quieren el mensaje directamente, otros que desean el contexto. Hay que saber ajustarse para diferenciarse.

Buenas Prácticas para Diseño de *Dashboards*

Consejo personal:


- Ver casos existentes.
- Sitios de visualización ofrecen interesantes guías:
 - [9 dashboard design principles: see them in action with real examples | Geckoboard blog](#)
 - [Visual Analysis Best Practices](#)
 - [Best Practices for Effective Dashboards - Tableau](#)
 - [Seven essential tips for designing better dashboards | Observable](#)

Dashboard - OCENSA


OCENSA

Cantidad de Personal

Personal por Posiciones



Evolución del personal



Cantidad actual

285

Permanencia meses

35


Rotación promedio

35

Promedio de edad

42

Composición por genero




Personal por dirección



Repartición geográfica del personal



Personal por area especifica




Dashboard - OCENSA

OCENSA


Rangos etarios

Baby Boomer	(1945-1964)
3	El trabajo es lo mas importante. Valora la productividad y no tolera el ocio. Aprecia los símbolos de status y el crecimiento vertical en una compañía
Personas	
Generación X	(1965 – 1981)
15	Sufrieron grandes cambios. Vida analógica en su infancia y digital en su madurez. Vivieron la llegada de internet.
Personas	
Generación Y	(1982-1994)
2	Son multitareas. No conciben la realidad sin tecnología. La calidad de vida tiene prioridad. Son emprendedores. Es la generación que usó más tipos de tecnología
Personas	
Generación Z	(1995-hoy)
265	Son "nativos digitales" (desde su niñez existe internet) Poseen alta propensión al consumo. Poseen acceso y manejo a toda tecnología. Ven a la tecnología como fundamental.
Personas	


Distribución por genero




Composición por Jefe Inmediato



Composición por posición



Promedio de Paga fija



Dashboard - OCENSA

OCENSA Movilidad

Contempla los movimientos a cargos de mayor nivel (promociones), de igual nivel (transferencias) dentro de la empresa o grupo empresarial y pueden ser definitivas o temporales por más de 90 días o remplazos (encargos) a cargos de liderazgo por más de 90 días.

Fecha inicial

19/09/2019

31/03/2020

Fecha Final

07/01/2020

20/08/2020

Áreas

All

Nombre

All

Tipo movilidad	Nombre	Cargo Inicial	Nivel Cargo inicial	Cargo final	Nivel Cargo final	Área	Fecha inicial	Fecha Final
	HERNANDEZ	GERENTE OPERACIÓN Y MANTENIMIENTO SUR		DIRECTOR ABASTECIMIENTO (E)		ABASTECIMIENTO	18 November 2019	
	GARZON	JEFE DE RESPONSABILIDAD INTEGRAL		GERENTE DE RESPONSABILIDAD SOCIAL		RESPONSABILIDAD INTEGRAL	21 March 2020	
	RIOS	JEFE ASESORÍA LEGAL ABASTECIMIENTO		GERENTE ESTRATEGIA Y ASESORÍA LEGAL		LEGAL Y ASUNTOS CORPORATIVOS	24 February 2020	20 August 2020
	HINCAPIE	SUPERINTENDENTE DE LÍNEA Y MANTENIMIENTO MAYOR SUR		GERENTE OPERACIÓN Y MANTENIMIENTO SUR (E)		OPERACIONES	18 November 2019	
	BECERRA	PROFESIONAL SENIOR ASESORÍA LEGAL ABASTECIMIENTO		JEFE ASESORÍA LEGAL ABASTECIMIENTO		LEGAL Y ASUNTOS CORPORATIVOS	03 March 2020	20 August 2020
	ALFONSO	PROFESIONAL INSPECTOR MECÁNICO Y CONTINGENCIAS		JEFE MECÁNICA Y CONTINGENCIAS (E)		OPERACIONES	18 November 2019	
	MARULANDA	PROFESIONAL ABASTECIMIENTO		LIDER DE CATEGORÍA		ABASTECIMIENTO	24 March 2020	
	TORRES	TÉCNICO OPERADOR CONSOLA		PROFESIONAL CUARTO CONTROL BOGOTÁ		OPERACIONES	03 March 2020	30 June 2020
	MOYA	ANALISTA DE REPORTES		PROFESIONAL DE PRESUPUESTO		ESTRATEGIA Y FINANZAS	16 January 2020	07 January 2020
	GUZMAN	PROFESIONAL CUARTO CONTROL BOGOTÁ		PROFESIONAL SENIOR CONFIABILIDAD - INSTRUMENTACIÓN		OPERACIONES	03 March 2020	30 June 2020
	HOLGUIN	PROFESIONAL SENIOR CAPACIDAD ORGANIZACIONAL		PROFESIONAL SENIOR TALENTO HUMANO (E)		ORGANIZACIÓN Y TALENTO	11 January 2020	03 August 2020
	GARCIA	EXPERTO INTELIGENCIA MERCADO Y NEGOCIOS		SUBGERENTE CRECIMIENTO Y REGULACIÓN		ESTRATEGIA Y FINANZAS	31 March 2020	



Visualización de Información y Analítica Visual

— Hernán Valdivieso López (hfvaldivieso@uc.cl) —
